

ViraLift: Tổng Quan Tool Và Báo Cáo Validation

Mục Lục

- [1. ViraLift Là Gì?](#)
- [2. Tool Chạy Như Thế Nào?](#)
- [3. Ví Dụ Sử Dụng](#)
- [4. Validation Dataset](#)
- [5. Cách Tính Accuracy](#)
- [6. Kết Quả Tổng Quan](#)
- [7. Breakdown Theo Gene: FMD](#)
- [8. Breakdown Theo Gene: PRRSV](#)
- [9. Finding Chính](#)
- [10. Kết Luận](#)

1. ViraLift Là Gì?

ViraLift là tool hỗ trợ chuẩn hóa và chuyển annotation gene/peptide cho virus genome.

Mục tiêu chính:

- Chuẩn hóa tên gene từ nhiều cách đặt tên khác nhau trong GenBank.
- Nếu query genome đã có annotation đủ tốt, tool trích xuất trực tiếp từ annotation.
- Nếu query genome chưa có annotation hoặc annotation thiếu, tool dùng reference chuẩn do user cung cấp để lift gene bằng tblastn.
- Xuất kết quả thành bảng TSV và FASTA để user kiểm tra hoặc dùng tiếp.

Tool hiện được validate chính trên 2 nhóm virus:

- FMDV: dùng mat_peptide, gene/peptide thường liên tiếp.
- PRRSV: dùng CDS/ORF, có nhiều gene chồng lấp và convention annotation phức tạp hơn.

2. Tool Chạy Như Thế Nào?

Pipeline chính:

1. User cung cấp reference GenBank đã annotation chuẩn.
2. Tool đọc reference và xác định feature type hữu ích, ví dụ CDS hoặc mat_peptide.
3. Tool chuẩn hóa tên gene bằng alias map.
4. Với mỗi query genome:
 - Nếu query có annotation đủ hữu ích, tool direct extract.
 - Nếu query thiếu annotation, tool dùng tblastn để map protein từ reference sang genome query.
5. Tool validate boundary:
 - Với CDS: kiểm tra start/stop codon và frame.
 - Với mat_peptide: không dùng start/stop codon vì peptide cleavage product không nhất thiết có ATG/stop riêng.
6. Tool xuất:
 - bảng prediction,
 - FASTA sequence,

- run summary,
- status cho từng gene.

Với tblastn lifting:

- Reference feature được dịch sang protein.
- Protein được search trên query genome bằng tblastn.
- HSPs được merge để suy ra tọa độ nucleotide.
- Tool chỉnh boundary nếu cần, ví dụ terminal extrapolation cho FMD hoặc start-codon rescue cho PRRSV.

HSP là một đoạn alignment tốt do BLAST trả về. Một gene có thể có một hoặc nhiều HSP. ViraLift dùng các HSP này để suy ra vùng nucleotide tương ứng trên query genome.

3. Ví Dụ Sử Dụng

Ví dụ chạy bằng CLI:

```
python -m app.src.main \ --reference app/data/PRRS_ref_test.gb \ --query
app/data/PRRS_PP946131_noAnno.gb \ --output output/prrs_example
```

Ví dụ logic kết quả:

```
ORF5 -> lifted bằng tblastn, tọa độ đúng, status ok ORF7 -> lifted bằng tblastn, start được rescue,
status ok_rescued ORF2b -> lifted đúng nhưng một s query truth có thể không annotate ORF2b riêng
```

Ý nghĩa status thường gặp:

- ok: lift thành công, boundary hợp lệ.
- ok_rescued: boundary ban đầu chưa ổn, tool đã rescue lại.
- ok_extrapolated: boundary được mở rộng bằng terminal extrapolation.
- no_hit: không tìm được hit phù hợp.
- invalid_boundaries: tìm được vùng nhưng boundary/codon validation chưa đạt.

Với CDS, invalid_boundaries có thể xảy ra nếu thiếu start codon, thiếu stop codon, hoặc CDS length không chia hết cho 3 (in_frame = false).

4. Validation Dataset

Validation dùng 2 bộ virus annotated records:

- FMDV strict-clean records.
- PRRSV strict-clean records.

Nguyên tắc lọc strict-clean:

- Chỉ giữ record có annotation đủ để làm ground truth.
- Tên gene phải map được về canonical name qua alias map.
- Với PRRSV, không dùng nested-feature filter mù vì ORF2b có thể overlap/nest trong ORF2a nhưng vẫn là gene thật.
- Với các gene không xuất hiện trong truth của một query record, không dùng record đó để chấm accuracy cho gene đó.

Ví dụ:

- Reference có ORF7.
- Trong 95 PRRSV records, truth có ORF7 ở 94 records.
- Vậy accuracy của ORF7 chỉ tính trên 94 records đó.

Điều này giúp tránh đánh giá sai tool vì annotation truth thiếu hoặc dùng convention khác.

5. Cách Tính Accuracy

Validation được tính theo từng gene.

Các metric chính:

- **total**: số query records thật sự có gene đó trong truth.
- **exact**: prediction khớp hoàn toàn tên gene + start + end.
- **coord_only**: tọa độ đúng theo IoU threshold nhưng không exact tuyệt đối.
- **failed**: không exact và cũng không coordinate-correct.
- **accuracy_pct** = (exact + coord_only) / total.
- **IoU**: chỉ số đo mức overlap giữa tọa độ prediction và tọa độ truth.

IoU Là Gì?

IoU là viết tắt của Intersection over Union.

Nói đơn giản:

$$\text{IoU} = \frac{\text{độ dài phần prediction và truth chồng lên nhau}}{\text{độ dài vùng bao phủ bởi cả prediction và truth}}$$

Ví dụ 1: prediction khớp hoàn toàn truth

Truth: 100 – 199 Prediction: 100 – 199 IoU = 100 / 100 = 1.00

Ví dụ 2: prediction lệch một chút nhưng vẫn gần đúng

Truth: 100 – 199 Prediction: 103 – 199 Overlap = 97 bp Union = 100 bp IoU = 0.97

Ví dụ 3: prediction lệch nhiều hơn

Truth: 100 – 199 Prediction: 130 – 199 Overlap = 70 bp Union = 100 bp IoU = 0.70

Trong validation này, một prediction được tính là **coord_correct** nếu:

same-gene truth t_in tại và IoU >= 0.90

Vì vậy:

- **IoU = 1.00**: tọa độ khớp hoàn toàn.
- **IoU >= 0.90**: tọa độ đủ gần, tính là coordinate-correct.
- **IoU < 0.90**: tính là failed về tọa độ.

Lưu ý quan trọng:

- Với gene dài, lệch vài bp thường IoU vẫn cao.
- Với gene rất ngắn như FMD 2A, chỉ lệch 6 bp cũng có thể làm IoU tụt dưới 0.90.
- Vì vậy một số failed cases ở gene ngắn không nhất thiết là lift sai vùng lớn, mà là boundary precision bị strict scoring phạt mạnh.

Ví dụ:

ORF7 total = 94 exact = 91 coord_only = 0 failed = 3 accuracy = 91 / 94 = 96.81%


Lý do tách exact và coord_only:

- **exact** đo boundary precision rất nghiêm ngặt.
- **coord_only** cho biết tool đã tìm đúng vùng gene, dù start/end lệch nhỏ hoặc annotation convention khác.
- Với virus annotation, nhiều case lệch vài bp có thể do convention, không nhất thiết là localization failure.

6. Kết Quả Tổng Quan

Kết quả sau các cải thiện hiện tại:

Overall validation accuracy by virus



Overall accuracy by virus


Virus	Total gene-record cases	Exact	Coord only	Failed	Accuracy
FMD	1149	1114	16	19	98.35%
PRRSV	761	674	84	3	99.61%
All	1910	1788	100	22	98.85%

Diễn giải:

- FMD đạt 98.35% khi tính exact + coordinate-correct.
- PRRSV đạt 99.61% khi tính trên các gene thật sự có trong truth.
- Phần lớn lỗi còn lại là boundary issue nhỏ hoặc annotation/ref-truth mismatch.

Figure dưới đây breakdown theo từng gene. Màu xanh đậm là exact, xanh nhạt là coord-only, đỏ là failed.

Per-gene accuracy on records where each gene exists in truth




7. Breakdown Theo Gene: FMD

FMD dùng mat_peptide, nên tool không dùng codon rescue mà dùng terminal extrapolation cho các case HSP thiếu amino acid ở đầu/cuối.

Evidence chính cho cải thiện FMD:

FMD strict-clean accuracy before vs after terminal extrapolation



FMD terminal extrapolation accuracy comparison

Gene	Total	Exact	Coord only	Failed	Accuracy
Lpro	96	96	0	0	100.00%
VP4	95	95	0	0	100.00%
VP2	96	95	0	1	98.96%
VP3	95	95	0	0	100.00%
VP1	95	79	16	0	100.00%
2A	96	79	0	17	82.29%
2B	96	96	0	0	100.00%
2C	96	96	0	0	100.00%
3A	96	95	0	1	98.96%
3B	96	96	0	0	100.00%
3Cpro	96	96	0	0	100.00%
3Dpol	96	96	0	0	100.00%

Finding chính của FMD:

- Hầu hết gene đạt gần hoặc đúng 100%.
- VP1 có nhiều coord_only: tool tìm đúng vùng nhưng boundary không exact.
- 2A là gene ngắn, chỉ lệch vài bp cũng làm IoU tụt dưới threshold.
- Một số lỗi còn lại ở VP2 và 3A cần manual review riêng.


Cải thiện đã làm:

- Terminal extrapolation dùng HSP query protein coordinates để bù amino acids thiếu ở terminal.
- Trong raw FMD comparison, exact accuracy tăng từ 94.44% lên 96.70%.
- Trong final per-gene truth-available summary, FMD exact đạt 96.95% và coordinate-correct đạt 98.35%.
- Tool-side failures giảm rõ, đặc biệt ở các case thiếu N-terminal 12 bp.

8. Breakdown Theo Gene: PRRSV

PRRSV dùng CDS/ORF và có overlapping genes, ví dụ ORF2a/ORF2b.

Evidence chính cho cải thiện PRRSV start rescue:



PRRSV start rescue exact comparison

Gene	Total	Exact	Coord only	Failed	Accuracy
ORF1a	62	61	1	0	100.00%
ORF1b	83	0	83	0	100.00%
ORF2a	95	95	0	0	100.00%
ORF2b	48	48	0	0	100.00%
ORF3	95	95	0	0	100.00%
ORF4	95	95	0	0	100.00%
ORF5	95	95	0	0	100.00%
ORF6	94	94	0	0	100.00%
ORF7	94	91	0	3	96.81%

Finding chính của PRRSV:

- ORF2a, ORF2b, ORF3, ORF4, ORF5, ORF6 đạt 100%.
- ORF1b có 0 exact nhưng 83 coord_only, nghĩa là tool tìm đúng vùng nhưng exact boundary khác truth. Đây là start/frameshift convention, không phải localization failure.
- ORF7 là lỗi chính ở baseline, do start rescue chọn nhầm internal ATG.

Cải thiện đã làm:


- Thêm check CDS frame: `len(CDS) % 3 == 0`.
- Start rescue không chọn ATG gần nhất một cách mù.
- Ưu tiên ATG tạo CDS đúng frame và có length gần reference.

Kết quả cải thiện PRRSV:

- ORF7 tăng từ 66/94 lên 91/94.
- ORF2b, ORF4, ORF5, ORF6 cũng tăng exact vì boundary-only cases được sửa.
- 3 case ORF7 còn lại có truth dài hơn reference, nên không nên auto-fix bằng ref-length rescue.

ORF7-only experiment cũng xác nhận đúng cơ chế lỗi:

ORF7 start rescue: baseline vs ref-length scoring



ORF7 rescue accuracy comparison

9. Finding Chính

Các finding quan trọng:

1. Accuracy phải tính trên gene thật sự có trong truth.
 - Nếu query truth không annotate gene đó, không thể dùng case đó để kết luận tool sai.
2. FMD và PRRSV cần xử lý khác nhau.
 - FMD dùng mat_peptide: phù hợp với terminal extrapolation.
 - PRRSV dùng CDS: phù hợp với codon/frame-aware rescue.
3. tblastn thường tìm đúng vùng gene.
 - Lỗi chính không phải search sai vùng lớn.
 - Lỗi thường nằm ở boundary start/end.
4. ORF1b PRRSV cần interpretation riêng.
 - Coord đúng 83/83.
 - Exact fail do frameshift/start-boundary convention.
5. Gene ngắn như FMD 2A dễ bị loU phạt mạnh.
 - Lệnh 6 bp ở gene rất ngắn có thể làm loU dưới 0.90.

10. Kết Luận

ViraLift cho kết quả tốt trên cả FMD và PRRSV khi validation được tính đúng theo same-gene truth availability.

Kết quả cuối:

- FMD: 98.35%
- PRRSV: 99.61%
- Tổng 2 tập: 98.85%

Kết luận kỹ thuật:

- tblastn là hướng phù hợp cho annotation transfer khi query thiếu annotation.
- Các lỗi còn lại chủ yếu là boundary precision hoặc annotation convention mismatch.
- Terminal extrapolation cải thiện FMD.

- Frame/ref-length-aware start rescue cải thiện PRRSV, đặc biệt ORF7.

Một câu tóm tắt:

ViraLift reliably transfers viral gene annotations using reference-guided tblastn lifting. On strict-clean FMDV and PRRSV validation datasets, the tool achieves high localization accuracy, with remaining failures mostly caused by short-feature boundary sensitivity or reference/query annotation convention differences.